




➤ Études longitudinales et stabilité des échantillons

Distinguer le signal biologique, prévenir les biais et harmoniser les trajectoires métabolomiques

Elfried M. B. SALANON — UCA · INRAE · UNH · PFEM / MetaboHUB Clermont

École chercheur de métabolomique clinique — RFMF × SFBC · 2026




Trois cas d'études longitudinales

Longitudinale by design

suivi planifié dès le départ



Cohorte de patients
suivie prospectivement



Réutilisation de données

cohorte réutilisée a posteriori



Biobanque
(échantillons)



Bases de données
existantes



Dossiers
archivés



Réutilisation
et reconstruction
de la trajectoire



Longitudinale fractionnée

phases séparées pour raisons financières




Contraintes
financières

Phase 1

(par ex. subvention 1)

Phase 2

(par ex. subvention 2)



Même objectif : décrire une trajectoire dans le temps, mais avec des contraintes de conception différentes.

INRAE



UNIVERSITÉ
DE GENÈVE



Plate-Forme
EXPLORATION du METABOLISME



Une trajectoire observée... mais quel temps mesure-t-on ?

Quand un métabolite varie entre T0 et T3, cette variation peut provenir de plusieurs horloges simultanées.



Temps biologique

Maladie

Traitement

Âge / saison




Temps échantillon

Pré-analytique

Stockage

Freeze-thaw



Temps analytique

Batch

Ordre d'injection

Dérive instrumentale

Objectif : attribuer la variation au bon mécanisme — avant de l'interpréter biologiquement.


INRAE



UNIVERSITÉ
DE GENÈVE



Pourquoi une étude longitudinale est différente d'une étude transversale ?



Les observations
ne sont pas indépendantes

Variabilité
intra- vs inter-individuelle

Visites manquantes
& temps irréguliers

Trajectoires non linéaires
possibles


→ La structure de corrélation fait
partie de la question scientifique.

Le paradoxe du stockage : T0 est souvent l'échantillon le plus "vieux"

Suivi clinique



Durée de stockage



Temps clinique



Durée de
stockage

Si les deux sont parfaitement
corrélés, le modèle statistique ne
peut pas séparer leurs effets.

Le problème n'est pas seulement la stabilité : c'est l'identifiabilité du signal temporel.

Stabilité : que cherche-t-on réellement à démontrer ?


- 1 Pré-analytique** Délai, température, centrifugation, hémolyse
- 2 Stockage** Température, durée, aliquotage, freeze–thaw
- 3 Analytique** Réponse instrumentale, RT, dérive, batch
- 4 Interprétative** Variation assez faible pour préserver la conclusion

$p > 0,05 \neq$ preuve de stabilité


Stabilité = variation sous une marge acceptable

Design d'une étude de stabilité : appairer avant de comparer

Même prélèvement →
aliquots



Analyse dans une séquence équilibrée + QC réguliers



Analyse en communs: Randomisation & QC

Empêcher le temps analytique d'imiter le temps biologique

À éviter :

séquence structurée par le temps clinique



Ordre d'injection $\approx$ temps clinique
→ dérive potentiellement confondue

Préférer : conditions alternées + QC




Les QC mesurent la dérive ;
la randomisation pour contrôler la
confusion.

Une correction de batch n'est fiable que si le design laisse encore l'information nécessaire pour estimer le batch.

Fractionné ou en réutilisation

- SRM
- Les QC communs,
- Réinjection d'échantillons,

Cas 1 — NIST SRM1950 : le même matériau mesuré pendant un an



Toute trajectoire observée révèle la chaîne analytique.

Le design rend la dérivation observable

Références, dilutions, pools et événements analytiques documentés

- 2 plasma « NIST1_1 & NIST1_2 » = no dilution
 - 1 plasma « NIST8 » = diluted x 8
 - 1 plasma « NIST4 » = diluted x 4
 - 1 plasma « NIST2 » = diluted x 2
 - 3 plasma « NIST1_3, NIST1_4 et NIST1_5 » = no dilution
 - 4 blanks of injection solvent
 - 3 pools for equilibration
 - diluted pools
 - 3 pools
 - Samples....
- } Classic sequence

Ce qui reste fixe

- SRM : NIST SRM1950
- QCs
- séquence de référence
- niveaux de dilution

Ce qui change


- projet / matrice
- colonne
- maintenance / nettoyage
- ordre d'injection
- temps



La répétition d'un même matériau crée un "pont" entre états analytiques.

Au-delà du RSD : représenter la structure de la variabilité

- An Euclidean space is defined by a plane made of the "measurement order" (X-axis) and the "intensity" (Y-axis) of the analyte signal.
- The proposed visualization methods is made of convex hulls based on the intensities of repeated QC measurements by batch.



IntraD

Dispersion
à l'intérieur du batch

Intra batch dispersion indicator

$$IntraD = \text{median}\left(\frac{A_t \cdot n_t}{n}\right)$$

with $t = 1, \dots, h$ and $h > 1$

Inter batch dispersion indicator

$$InterD = \frac{\Delta_{\text{injection order}} * \Delta_{\text{intensity}}}{2}$$


Ratio

$$D - \text{Index} = \frac{IntraD}{1 + InterD}$$

The key properties include:

Translation Invariance, Positivity, Stability

Convex Hull Visualization; Centroid Tracking; Gradient Visualization



ALLOW A VISUALIZATION OF THE ANALYTICAL DRIFT
IN TWO DIMENSIONS, TO FACILITATE RESULT
INTERPRETATION.

InterD

Gradient
entre batches


D-Index

Structure globale
de dispersion


→ ABILITY TO CAPTURE THE VARIABILITY OBSERVED EITHER IN PARAMETRIC OR NON-PARAMETRIC CONDITIONS.

La variabilité analytique n'affecte pas tous les métabolites de la même façon

NIST SRM1950: plasma reference material




THIS VISUALIZATION TOOL CAN ALSO BE USED TO IDENTIFY EFFICIENTLY, SIMILAR BEHAVIOURS (DISPERSION, SENSITIVITY TO BATCH EFFECT) WITHIN ANALYTES



Même NIST



Profils de dispersion et de drift différents




→ Un CV global identique peut masquer des dynamiques analytiques très différentes.

INRAE



Des trajectoires qui se superposent




Le piège longitudinal



Si temps clinique $\approx$ temps de stockage $\approx$ batch, l'interprétation devient non identifiable.

Cas 2 — Une cohorte analysée en deux temps : un scénario réel



320 subjects were analyzed at T1=March 2015 (Batches 1 to 4); and **248 subjects** analyzed at T2=March 2016 (Batches 5 to 7). n=144 injected twice.

Pujos-Guillot et al, 2019

Mars 2015

320 sujets
Batches 1–4

Mars 2016


248 sujets
Batches 5–7

144 échantillons
réinjectés

Les 144 réinjections jouent le rôle de “bridge samples”

Campagne T1 — B1 à B4

Campagne T2 — B5 à B7



Principe général : créer des ponts analytiques avant que les campagnes ne deviennent incomparables.

QCs communs:LOESS

Requirement

- Meme QCs entre les sequences.
- Dataset avec les mêmes noms de variables
- metadata

Sortie

**dataset harmonisé
utilisable.**
NB: toujours évaluer en sortir.



Workflow4metabolomics



ComBAT : une stratégie de rattrapage post-acquisition

Requirement

- Dataset avec les mêmes noms de variables.
- Ajouter les variables indicatrices du batch.


Sortie

**dataset harmonisé
utilisable.**
NB: toujours évaluer en sortir.



PARSEC : une stratégie de rattrapage post-acquisition

Harmoniser lorsque les acquisitions ont déjà été réalisées séparément



$$\widehat{y'}_{ij} = \frac{y_{ij} - \bar{y}_i}{\sigma_{y_i}}$$

$$Y' = X\beta + \sum_{k=1}^K Z_k A_k + U = X\beta + ZA + U$$



Workflow4metabolomics

INRAE



UNIVERSITÉ
DE GENÈVE




Plate-Forme
EXPLORATION du METABOLISME




Salanon et al., *Analytica Chimica Acta*, 2025 — DOI 10.1016/j.aca.2025.344753

Sans harmonisation, le temps analytique est confondus avec la structure des données.



PCA of Case study 1 data. The same samples (n=144) were analysed at T1=March 2015 (Batches 1 to 4) and T2=March 2016 (Batches 5 to 7) before (a) and after (b) corrections. Number of ions = 3,577.



Avant : study / batch / injection order dominant

Après : structure technique fortement réduite

INRAE



UNIVERSITÉ
DE GENÈVE




Plate-Forme
EXPLORATION du METABOLISME



Cas T1/T2 — mêmes 144 échantillons ; 3 577 ions


Ce que l'on peut faire dépend du moment où l'on agit




Plus on anticipe tôt, moins on dépend de corrections statistiques post hoc.

Après correction : ne pas conclure trop vite

Une correction doit être évaluée sur plusieurs dimensions



Validation ciblée : landmark compounds + cohérence isotopique



Isotopic ratios , before and after correction, using the QC samples analyzed within the nine batches

Landmark compounds	Average intensities			Isotopic Ratio (13C/12C)				Standard deviation of the Isotopic ratio		
	Without correction	LOESS	ComBat	Without correction	LOESS	ComBat	Theoretical	Without correction	LOESS	ComBat
Arginine	255431.07	252915.41	255280.12	8.65	8.69	8.55	8.20	1.10	1.10	1.23
Ippuric acid	124778.80	125936.42	125081.02	11.99	11.83	11.97	10.30	1.60	1.41	1.32
heobromine	175638.69	175717.00	175633.78	9.44	9.45	9.21	9.20	1.57	1.55	1.82
Tyrosine	1648241.47	1648516.32	1647534.54	11.49	11.46	11.49	10.30	0.42	0.49	0.40
affeine	594063.33	599396.73	593703.24	10.85	10.86	10.85	10.30	0.78	0.69	0.65
Tryptophan	2467803.36	2463565.55	2463281.09	14.55	14.61	14.56	12.80	1.53	1.33	0.67
henylacetylglutamine	109072.62	109755.39	109691.28	16.41	16.08	16.19	15.10	2.52	2.20	2.51
ecanoyl-carnitine	79347.80	79185.98	79435.94	19.61	19.67	19.62	19.30	2.06	1.90	2.12
reatinine	1326372.13	1329412.24	5025833.73	5.34	5.38	6.85	5.50	1.16	1.16	1.15
Proline	5016879.31	5057731.28	977707.24	6.85	6.86	7.13	6.00	0.25	0.18	0.21
Ipecolic acid	978320.80	982817.45	875383.14	7.30	7.31	5.22	7.10	2.79	2.27	1.59
reatine	873001.58	878834.40	461399.23	5.46	5.50	8.13	5.60	1.06	1.27	1.40
Leucine	471825.89	472451.13	150803.45	7.95	7.88	7.19	7.10	1.24	1.02	1.77
rigonelline	150620.11	151560.06	715147.65	7.64	7.45	7.30	8.10	1.37	1.93	1.47
Lysine	724408.40	722198.92	1196698.18	7.23	7.19	7.07	7.50	1.69	1.58	1.87
Glutamic acid	129587.76	130848.18	129510.87	6.01	6.01	5.74	6.00	1.51	2.63	1.38
Methionine	1198202.47	1201474.60	1196698.18	7.06	7.06	7.07	6.80	50.61	35.85	3.00

Univarié : CV, IntraD, InterD, D-Index

Chimie : préserver les ratios isotopiques attendus

INRAE

UNIVERSITÉ DE GENÈVE

METABOHUB

Plate-Forme EXPLORATION du METABOLISME

Salanon et al., Metabolomics, 2026

Analyse longitudinale univariée : séparer sujet, temps et nuisance analytique


$$Y_{i\Box\Box} = \beta_0 + \beta_1 \cdot \text{Temps} + \beta_2 \cdot \text{Groupe} + \beta_3 \cdot \text{Temps} \times \text{Groupe} + u_i + \gamma \text{Batch} + \varepsilon_{i\Box\Box}$$



trajectoire
moyenne



niveau / pente
individuelle



nuisance
analytique




différence de
trajectoire

Attention si correction préalable

Le modèle mixte gère les répétitions. Il ne peut pas séparer un temps parfaitement confondu avec le batch.

→ Le modèle complète le design ; il ne le remplace pas.

Quand le longitudinal devient multi-source : harmoniser puis intégrer



➔ A novel **cooperative learning framework** for vertical data integration in untargeted metabolomics is proposed

1. Harmoniser

2. Contrôler

3. Intégrer

Cooperative learning :
chercher des signaux
communs robustes entre
blocs / cohortes.

Ce n'est pas une méthode
de correction de batch.

INRAE



UNIVERSITÉ
DE GENÈVE



Plate-Forme
EXPLORATION du METABOLISME



Salanon et al., Comput Struct Biotechnol J., 2026 — cooperative learning framework

À retenir : prévenir, corriger, récupérer... et savoir ce qui est perdu

PRÉVENIR	CORRIGER	RÉCUPÉRER	NON RÉCUPÉRABLE
randomisation	dérive QC-based	re-extraction commune	temps = batch parfait
bridges / RM / QC	batch correction	PARSEC	metadata absente
metadata	modèle longitudinal	harmonisation multi-source	échantillons non comparables


1. La stabilité est une propriété de la chaîne de mesure — pas seulement de l'échantillon.

2. En longitudinal, le meilleur correcteur de batch reste un design qui évite la confusion.

3. Une correction doit être démontrée fiable avant toute analyse et ou interprétation biologique ou réutilisation.

Merci pour votre attention

Questions / discussion



Attribuer le bon temps au bon signal.
elfried.s@healin.fr