

Annotation & métabolites

Identifier les molécules à partir des données spectrales : rôle potentiel des LLM

Objectif : proposer une structure chimique aussi fiable que possible à partir de données de spectrométrie de masse (MS/MS) et, si disponibles, de RMN, en combinant plusieurs niveaux de preuve et une validation experte.

1. De quoi s'agit-il ?

L'annotation métabolique consiste à interpréter des données analytiques — par exemple masse exacte, spectres MS/MS, fragments et données RMN — afin de proposer l'identité d'un composé ou une structure chimique candidate. Le niveau de certitude dépend des données disponibles et des références de comparaison.

Niveaux de confiance : du signal à l'identification

Niveau 1 — Identification confirmée : Comparaison avec un standard authentique analysé dans des conditions comparables, avec plusieurs critères concordants selon la méthode.

Niveau 2 — Annotation probable : Correspondance convaincante avec une bibliothèque ou des données de référence, sans confirmation complète par un standard authentique.

Niveau 3 — Classe ou famille de composés : Les données soutiennent une famille chimique ou une structure partielle, mais ne permettent pas de trancher entre isomères ou candidats proches.

Niveau 4 — Formule ou caractéristiques élémentaires : Proposition fondée sur la masse exacte, la formule moléculaire ou des indices limités ; la structure reste indéterminée.

Les échelles de confiance varient selon les disciplines et les publications. Les niveaux ci-dessus sont une synthèse pratique : il faut préciser l'échelle adoptée et ne pas présenter une hypothèse comme une identification confirmée.

2. Bénéfices possibles des LLM

Aide à la recherche bibliographique : Explorer les connaissances publiées sur une molécule, une voie métabolique ou une famille chimique et proposer des termes de recherche.

Interprétation assistée des spectres : Aider à organiser les fragments observés, les pertes neutres possibles et les hypothèses de fragmentation, à confronter ensuite aux données et à la littérature.

Utilisation de spectres multiples : Structurer la comparaison de plusieurs spectres ou de données MS/MS et RMN, si le modèle et le format d'entrée le permettent.

Identification de pistes pertinentes : Proposer des candidats, des familles chimiques ou des molécules associées à examiner, sans conclure sur la seule base d'une réponse textuelle.

Exploration de voies métaboliques : Aider à formuler des hypothèses sur les relations entre métabolites et les transformations plausibles, à vérifier expérimentalement.

Gain de temps : Résumer des articles, comparer des candidats et produire un tableau des indices favorables, défavorables et manquants.

3. Précautions et garde-fous

Point de vigilance	Bonne pratique
Ne pas surinterpréter	Un LLM peut produire une hypothèse plausible mais erronée ; une suggestion n'est pas une preuve d'identité.
Vérifier les références	Contrôler les articles, bases de données, identifiants et spectres cités dans les sources originales.
Conserver l'expertise humaine	Les chimistes analytiques et spécialistes du métabolisme doivent examiner les propositions et les alternatives.
Connaître les mécanismes	Interpréter les mécanismes de fragmentation, les pertes neutres et les voies métaboliques à partir de connaissances validées.
Maintenir un esprit critique	Comparer plusieurs candidats, signaler les isomères possibles et documenter les incertitudes.
Préserver les compétences	Utiliser l'outil comme soutien à l'apprentissage, pas comme substitut à la compréhension scientifique.
Préserver le plaisir scientifique	Garder une place à l'exploration personnelle et au raisonnement, pour éviter une dépendance excessive à l'outil.

4. Workflow recommandé

1. Rassembler les preuves : Masse exacte, formule candidate, spectres MS/MS, données RMN, temps de rétention et métadonnées disponibles.
2. Générer des hypothèses : Utiliser les outils appropriés et, si utile, un LLM pour organiser les candidats et les indices.
3. Comparer : Confronter les fragments, pertes neutres, données de référence, littérature et voies métaboliques plausibles.
4. Qualifier la confiance : Distinguer identification confirmée, annotation probable, classe chimique et formule seulement.
5. Valider et documenter : Faire relire par un expert, conserver les preuves, les alternatives et les limites de l'interprétation.

5. Exemple de prompt réutilisable

Contexte : je cherche à annoter un composé à partir de données analytiques. Voici les données autorisées : [masse exacte, formule candidate, spectre MS/MS, données RMN, temps de rétention, conditions analytiques].

Aide-moi à :

1. résumer les indices expérimentaux disponibles ;
2. proposer plusieurs hypothèses de structure ou de famille chimique ;
3. relier chaque hypothèse aux fragments, pertes neutres ou signaux observés ;
4. préciser les preuves manquantes et les alternatives, notamment les isomères possibles ;
5. indiquer le niveau de confiance justifié par les données et les vérifications à effectuer.

N'invente aucune référence ni aucun résultat expérimental. Distingue clairement les observations, les hypothèses et les conclusions. Ne présente pas une annotation comme une identification confirmée sans preuve suffisante.

À retenir : les LLM peuvent accélérer la recherche, la comparaison et la formulation d'hypothèses en annotation métabolique. La confiance dans l'identification doit

toutefois être déterminée par les preuves analytiques, les références et la validation experte — pas par l'assurance du modèle.

Note : les niveaux de confiance présentés sont une synthèse pédagogique. Les systèmes de classification formels varient selon les domaines et doivent être appliqués selon la méthode ou la publication de référence.