

Ontologies et vocabulaire contrôlé pour des données FAIR et adaptées à l'IA

Magalie Weber, Ingénieure de Recherche, INRAE



Findable



Accessible



Interoperable



Reusable



AI-ready

Qui suis-je ?

- Ingénieure de formation agroalimentaire, spécialisée en ingénierie des connaissances (sémantique, ontologies)
- **INRAE, Unité de Recherche BIA (Biopolymères Interactions Assemblages) localisée à Nantes**
 - Equipe ISD (Interfaces Systèmes Dispersés) : interactions protéines-lipides-polyphénols dans les aliments
- **Département de Recherche TRANSFORM :**
 - Construction de la qualité des aliments, produits biosourcés, systèmes circulaires et durables
 - Responsable du développement de l'ontologie TransformON
- **Mission DipSO (Direction pour la Science Ouverte)**
 - Vocabulaires contrôlés : thésaurus, ontologies...
 - Principes FAIR, ouverture et partage des données
- **Membre du groupe de curation de l'ontologie FoodON (OBO Foundry)**
- **Membre invité de l'infrastructure MetaboHub**



Objectifs de la session




- **Comprendre :**
 - Ce que sont les principes FAIR et leur lien avec l'IA.
 - Ce que sont les ontologies, vocabulaires contrôlés, thésaurus, schémas de métadonnées.
- **Voir comment ces outils rendent les données FAIR et AI-ready.**
 - Illustrations à partir de quelques cas d'usages
- **Repartir avec des pistes d'action pour vos propres projets (cohortes, biomarqueurs, exposome).**
 - Mise en situation : “Intégration des données selon les principes FAIR : vers des données métabolomiques prêtes pour l'IA”

Contexte : explosion des données en métabolomique



- **Métabolomique: données complexes, multidimensionnelles, explosion du volume de données**
- **Métabolomique humaine : cohortes, exposome, maladies chroniques.**
 - Multiplication des cohortes et études cliniques (diabète, cancers, maladies cardiovasculaires, neurodégénératives...)
 - Projets exposome : milliers de métabolites endogènes et xénobiotiques
 - Aliments : qualité, sécurité, procédés de transformation...effets de l'alimentation sur la santé
- **Problèmes récurrents :**
 - Hétérogénéité des formats.
 - Métadonnées incomplètes ou libres.
 - Difficulté à combiner des jeux de données entre labos, espèces, matrices.
- **Besoin croissant de données structurées pour l'IA (biomarqueurs, pronostics, médecine personnalisée)**

FAIR et IA : le lien crucial



From FAIR to FAIR-R and FAIR²: AI Readiness (AIR) and Responsible AI (RAI)

Core Principles for AI-Ready Data (AIR)

1. **Findability:** Datasets should be discoverable, searchable and easily located through robust metadata, unique identifiers, and well-organized repositories.
2. **Accessibility:** Clear documentation and provenance metadata ensure that data is understandable and accessible to both humans and machines.
3. **Interoperability:** Standardized formats and metadata facilitate seamless integration and sharing of data across systems and platforms.
4. **Reusability:** Datasets should be formatted for downstream applications, including AI and machine learning workflows.
5. **Readiness for AI:** Datasets must be structured to meet the specific (quality) requirements of AI applications, such as labeled data for supervised learning or comprehensive coverage for unsupervised learning

Verhulst, Stefaan and Zahuranec, Andrew and Chafetz, Hannah, Moving Toward the FAIR-R principles: Advancing AI-Ready Data (March 04, 2025). Available at SSRN: <https://ssrn.com/abstract=5164337> or <http://dx.doi.org/10.2139/ssrn.5164337>

Les principes FAIR



FAIR & AI-READY DATA

- **Message clé :**

FAIR n'est pas un "label", c'est un ensemble de pratiques pour que les données soient utilisables par des humains et des machines.

- **Principes à respecter :**


- **Findable** : identifiants persistants, métadonnées riches, indexation
- **Accessible** : protocoles standards, conditions d'accès claires (dont aspects éthiques et légaux)
- **Interoperable** : formats ouverts, vocabulaires communs, ontologies
- **Reusable** : documentation, provenance, licences, standards communautaires



Source: [The Turing Way Community & Scriberia \(2024\)](#).

De FAIR à “AI-ready”

- **L’IA a besoin de :**
 - Données structurées, homogènes, bien annotées.
 - Métadonnées "machine-readable" (lisibles automatiquement).
- **FAIR est une condition nécessaire, mais pas toujours suffisante :**
 - Il faut ajouter de la sémantique, du contexte à l’aide de données structurées et documentées (métadonnées riches)
- **AI-ready : des données adaptées à l’entraînement, à la validation, à l’interprétation de modèles.**
 - **Enjeu : éviter des modèles biaisés ou non généralisables à cause de métadonnées pauvres.**






Critères “AI-readiness” (AIR) et “Responsible AI” (RAI)

- **Qualité et richesse des annotations** (variables bien définies, unités, codes).
- **Utilisation de standards et ontologies** (interopérabilité sémantique).
- **Provenance claire** (qui, quand, comment, avec quel instrument, quel protocole).
- **Documentation des biais** (cohortes, conditions expérimentales, matrices).
- **Licences et aspects éthiques** (santé humaine, données sensibles, accès équitable).

ontologies



métadonnées
standardisées



identifiants



FAIR² compliance certification : <https://sen.science/doi/10.71728/r1rj-f947/dashboard>



Pourquoi c'est indispensable en métabolomique

- **Problèmes classiques sans vocabulaires contrôlés :**

- “plasma”, “sang”, “serum” utilisés de façon incohérente.
- “glucose”, “D-glucose”, “Glc” sans lien explicite.
- Protocoles décrits en texte libre → impossible à comparer automatiquement.

Données
hétérogènes

- **Avec ontologies et vocabulaires contrôlés :**

- Chaque concept a un identifiant stable (ex. ChEBI:17234 pour glucose, mesh:D010949 pour plasma).
- Les relations sont explicites (ex. “plasma” est un type de “matrice biologique”).
- Les machines peuvent relier, agréger, filtrer correctement.
- L'IA peut « raisonner ».

Données
sémantiques

Ontologies et vocabulaire contrôlé



FAIR & AI-READY DATA

De quoi parle-t-on ?



Raisonner

Décrire le réel pour valider, simuler, générer de nouvelles connaissances


CLASSES



Abstraire

Indexer dans une ou plusieurs langues, documenter de manière non ambiguë

CONCEPTS



Classer


Organiser les objets numériques selon leurs propriétés ou leur thématique

TERMES



Normaliser

S'affranchir de la variabilité de la langue, proposer une recherche à facettes



Définitions simples



FAIR & AI-READY DATA

- **Liste d'autorité** : liste normalisée de termes non hiérarchisés
 - Ne contient pas de définition

- **Taxonomie** = ensemble de classes ou catégories organisées selon une hiérarchie
 - Ne contient que des relations d'inclusion, aussi dénommées subsumption (« est un »)

- **Terminologie ou lexique** : ensemble de termes relevant d'un même domaine d'activité qui a son vocabulaire propre
 - S'apparente au dictionnaire ou glossaire mais sur un domaine spécialisé (ex. médecine, informatique...)

- **Thésaurus** = liste organisée de termes contrôlés et normalisés qui expriment des concepts structurés entre eux à l'aide de relations bien définies (synonymie, hiérarchie, association).
 - Contient des définitions textuelles
 - Permet de gérer plusieurs langues

➤ La liste d'autorité et la terminologie se distinguent du thésaurus par leur représentation qui est dans un ordre alphabétique et sans hiérarchie.

➤ Par rapport à une taxonomie, le thésaurus se distingue par sa dimension linguistique (définitions textuelles, traductions).

Définitions simples

- **Ontologie** : ensemble structuré de concepts et de relations entre ces concepts avec des identifiants uniques (URI)


- Exemple : “échantillon” → “provient de” →
“sujet humain” → “diagnostiqué avec” →
“diabète de type 2”.

- Permet un raisonnement et une intégration sémantique poussée à l’aide du langage OWL W3C (logique de description formelle).



FAIR & AI-READY DATA

- ❖ Organisation des données sous la forme d’un **graphe**
- **interopérabilité** entre systèmes d’information
- contextualisation des données avec **des métadonnées**




Définitions simples

- **Schéma de métadonnées** : modèle structuré qui définit quels champs doivent être renseignés pour décrire les données (nom, type, obligatoire/optionnel).

- Exemple : DublinCore, DCAT, ISA-Tab, SDRF, schemas.org...

- **Un schéma de métadonnées** dit “quels champs remplir”, les ontologies et les thésaurus disent “avec quels termes les remplir”



Types de métadonnées

- **Métadonnées descriptives :**

- fournissent des informations sur un contenu afin d'améliorer sa découvrabilité, notamment le titre, l'auteur, les mots-clés et les résumés.

- **Métadonnées structurelles :**

- définissent la façon dont les données sont organisées et interconnectées au sein d'un système : le format et les relations entre les différents éléments de données.
- Elles fonctionnent comme une table des matières ou un plan qui aide les systèmes et les utilisateurs à naviguer logiquement dans des ensembles complexes.

- **Métadonnées administratives :**

- Elles permettent de gérer et de conserver les ressources digitales.
- **Métadonnées de conservation :** elles documentent l'historique, le format et les modifications associés à une ressource digitale (versions des fichiers, les dates de création et les modifications).
- **Métadonnées de gestion des droits :** elles régissent les autorisations d'accès et d'utilisation des contenus digitaux (informations relatives aux droits d'auteur, aux licences et aux restrictions).



"Designed by artmonkey / Freepik"

Ontologies vs vocabulaire contrôlé ?



FAIR & AI-READY DATA

- **Ontologie = modèle de représentation de la connaissance sur un domaine**

- Identifie les types d'entités à l'aide de classes et définit les relations spécialisées qui lient ces entités entre elles
- Peut aussi inclure un ensemble de règles logiques et de contraintes permettant à une machine de produire des raisonnements ou des nouvelles connaissances.
- Constitue la structure d'un graphe de connaissances.
- Degré de formalisme variable : spécialisé sur un domaine particulier (ontologie de domaine ou de tâche) ou générique et indépendant d'un domaine (ontologies plus formelles, abstraites).

- **Vocabulaire contrôlé = termes normalisés**

- Concrètement, l'intégration d'un lexique permet de proposer des solutions d'IA plus intelligentes qui traitent les demandes en fonction de leur sens, et non plus uniquement à partir de mots-clés.
- Un thésaurus permet d'apporter des définitions textuelles utiles pour la compréhension humaine et des identifiants uniques permettant aux concepts d'être manipulé par les machines
- Les ontologies se résument à des taxonomies si on ne les utilise que comme simple vocabulaire contrôlé






Où trouver les vocabulaires, schémas de métadonnées, ontologies ?

- **Catalogue FAIR Sharing**



<https://fairsharing.org/>



- **Portails et entrepôts dédiés**




EMBL-EBI
Ontology Lookup Service

<https://www.ebi.ac.uk/ols4/>




<https://bioportal.bioontology.org/>



<https://agroportal.eu/>



<https://ontobee.org/>



<https://obofoundry.org/>



Quelques ontologies ou standards à connaître

• **Ontologies**

- UBERON-Anatomy ontology
- PATO-the Phenotype And Trait Ontology
- ENVO- The Environment Ontology
- OBI-Ontology for Biomedical Investigations
- MONDO Disease Ontology-Monarch Initiative
- DOID- Human Disease Ontology
- HPO-Human Phenotype Ontology
- FoodON-The Food Ontology
- FOBI- Food Biomarker Ontology
- ONS- Ontology for Nutritional Studies
- FIDEO-Food Interactions with Drugs Evidence Ontology
- CHMO-Chemical Methods Ontology
- MSIO - Metabolomics Standards Initiative Ontology

• **Autres standards (Linked data RDF)**

- PSI-MS Ontology (MS) : Proteomics Standards Initiative Mass Spectrometry
- ChEBI : Chemical Entities of Biological Interest
- NCIT
- SNOMED CT
- MESH
- AGROVOC
- Thésaurus INRAE
- .../...



Autres ressources


Référentiels (termes métier, mais pas toujours sémantiques)

- Taxonomies: code international de nomenclature zoologique (CINZ), code international pour les algues, les champignons et les plantes (ICN), code pour la bactériologie et la virologie (ICTV).
- Nomenclature IUPAC-IUBMB: chimie pure et appliquée, biomolécules, enzymes
- Table Nationale de Codage en Biologie (TNB), Nomenclature des actes de biologie médicale (NABM)
- CIM : Classification internationale des maladies (CIM-10)
- Codage des médicaments : CIP (Code Identifiant de Présentation) ou UCD : Unité Commune de Dispensation
- Autres nomenclatures disciplinaires ou Bdd « métier » : DssTox, RefMet, HMDB, PubChem...
- .../...




pas obligatoirement d'alignements vers des concepts d'une ontologie ni d'URIs (identifiants uniques) associés

Comment ces outils rendent les données FAIR et AI-ready



Comment les ontologies rendent les données FAIR : Faciles à trouver



- **Métadonnées riches avec des termes normalisés**

- Exemple :

- au lieu de “sang”, on utilise un concept (blood) + matrice : blood plasma ou plasma

- diagnostics codés (MONDO, SNOMED CT, NCIT, DOID, CIM) pour filtrer par maladie

- **Résultat : requêtes précises (“plasma + diabète de type 2”)**

- meilleure indexation dans les moteurs de recherche.

- méta-analyses facilitées : on peut filtrer par type d’échantillon, espèce, organe, etc. dans les entrepôts de données.

blood

[NCIT:C12434](#)

[UBERON:0000178](#)

[mesh:D001769](#)

.../....

plasma

[NCIT:C13356](#)

[mesh:D010949](#)

[UBERON:0001969](#)


Comment les ontologies rendent les données FAIR : Accessible

- **En santé humaine, l'accès est souvent restreint** : données sensibles avec des obligations d'anonymisation/pseudonymisation, consentements spécifiques.
- **Les ontologies (ou vocabulaires) n'agissent pas directement sur l'accès technique, mais elles aident à :**
 - Décrire les niveaux d'accès (ouvert, contrôlé, restreint).
 - Encoder les licences et conditions d'usage.
 - Documenter les contraintes éthiques (consentement, usage secondaire) avec des termes standardisés.
- **Voir portail FReSH piloté par INSERM**




<https://portail-fresh.fr/>

Comment les ontologies rendent les données FAIR : Interopérable



- **Scénario typique : les échantillons et données proviennent de plusieurs cohortes**
 - Questionnaires différents.
 - Panels de composés mesurés partiellement différents.
 - Méthodes analytiques différentes (ciblé vs non ciblé).
- **Avec ontologies et vocabulaires contrôlés, on peut harmoniser :**
 - les types d'expositions (ENVO, ChEBI, PubChem).
 - les composés (ChEBI, DSSTox, PubChem...).
 - les biomarqueurs internes (ChEBI, FOBI, RefMet, HMDB...).
 - les résultats de santé- outcomes (MONDO, DOID, HPO, NCIT...)
- **Et représenter ces entités et leurs relations sous forme de graphes de connaissances**



Comment les ontologies rendent les données FAIR : Réutilisable

- **Réutilisabilité exige une provenance claire :**

- Qui a produit la donnée, avec quel instrument, quel protocole, quelle version de logiciel.
- Contexte expérimental ou clinique: design, traitements, contrôles, répétitions.
- Comment les expositions ont été mesurées / estimées ?
- Quels instruments, quelles méthodes analytiques ?
- Quels traitements des données (normalisation, imputation) ?

- **Les ontologies aident à :**

- Encoder la provenance de manière standardisée (ex. PROV-O).
- Décrire les activités, les rôles, les instruments, les protocoles (ex. OBI)
- **Bénéfice** : un autre chercheur (ou un pipeline IA) peut :
 - **Comprendre exactement comment les données ont été générées.**
 - **Décider si elles sont adaptées à sa question (ex. cancer vs maladies métaboliques).**
 - **Réutiliser les données sans ambiguïté.**


Données

Métadonnées
(+ontologies)

Publication
(dépôt)

Réutilisation
par humain / IA

Interopérabilité et Réutilisabilité : au cœur du sujet sémantique



- **Objectif: intégrer multi-sources et multi-échelles nécessitent :**

- Interopérabilité syntaxique : formats ouverts (mzML, mzTab-M, ISA-Tab/JSON) ;
- Interopérabilité sémantique : mêmes concepts, mêmes relations, mêmes identifiants ;
- Réutilisabilité : provenance et contexte.

Un fichier lisible
par les
machines

- **Un pipeline IA peut alors :**

- Fusionner les données d'exposition et de métabolomique.
- Entraîner des modèles sur plusieurs cohortes.
- Explorer des relations *exposition* → *métabolome* → *santé*, de façon systématique.

Méta-analyses
et modèles
prédictifs



La clef de la réutilisabilité : des données structurées et contextualisées

• Métadonnées enrichies :

- utilisent des vocabulaires contrôlés disciplinaires
- s'appuient sur des schémas et des standards
 - Un standard est décrit par un schéma qui a été adopté comme **modèle** par un ensemble d'utilisateurs : il est **reconnu, normalisé et utilisé à grande échelle**.
 - Si aucun standard dans sa discipline ne répond totalement aux besoins, **il est possible de créer son propre schéma de métadonnées** : concrètement, cela consiste à lister vos métadonnées sous forme de **tableur**, avec l'intitulé de la métadonnée d'un côté et le descriptif en face.



Attention : Seules les métadonnées renseignées selon un standard seront interopérables.

• Dictionnaire de données : de quoi parle-t-on ?

- référentiel centralisé qui stocke des métadonnées détaillées sur les données contenues dans une base de données ou un système d'information
- fournit une documentation complète et organisée sur toutes les caractéristiques et les aspects des données.

Data

client_id	name	dob	gender	marital_status	current_address	description
1	Ki Ding	03/02/01	M	Single	Osaka, Japan	-
2	Gu Fing	30/08/99	M	Single	Tokyo, Japan	Certificate for proof of date of birth is yet to be submitted
3	Joe King	02/11/99	M	Married	Nagoya, Japan	-

Data dictionary (Metadata)

	Column	Data type	Field size	Description
1	client_id	int	5	Client's ID
2	name	nvarchar	30	Client's fullname
3	dob	date	8	Date of birth as per client's documents
4	gender	char	2	M – Male, F – Female, NB – Non-binary
5	marital_status	char	30	Marital Status as described by the client
6	current_address	char	300	Current residential address as described by client
7	description	nvarchar	300	Notes

La clef de la réutilisabilité : des données structurées et contextualisées




FAIR & AI-READY DATA

- **Pourquoi la standardisation aide l'IA :**
 - **Réduction de l'ambiguïté :** Un vocabulaire unifié (comme un lexique ou une ontologie) évite qu'un même terme désigne des réalités différentes selon les sources.
 - **Interopérabilité des données :** Elle permet à des bases de données ou à des logiciels variés de partager des informations sans perte de sens.
 - **Précision accrue pour les modèles spécialisés :** Dans des domaines techniques ou médicaux, l'utilisation de termes normalisés sert de repère fiable pour entraîner des IA expertes.
 - **Amélioration du traitement du langage naturel (NLP) :** Elle aide les algorithmes à lier plus facilement les mots à leur sens précis et à interpréter correctement l'intention d'une requête.



Intelligence artificielle
hybride : Graphes + LLM




“Minimum information” en métabolomique ?

- **Métadonnées indispensables :**

- Design expérimental : type d'étude, critères d'inclusion/exclusion
- Sujets : âge, sexe, origine, BMI, diagnostics, phénotypes...
- Préparation d'échantillons (conditions)
- Acquisition (instrument, méthode, paramètres)
- Traitement des données : logiciels, versions, paramètres, normalisation

Quoi décrire

Métadonnées



Comment décrire

Schéma de métadonnées
+ vocabulaire contrôlé

Schémas de métadonnées et “minimum information” en pratique



FAIR & AI-READY DATA


- **ISA-Tab / ISA-JSON (LinkedISA) :**

- Structure “Investigation – Study – Assay”.
- Très utilisé en métabolomique, transcriptomique, etc.
- Peut intégrer des termes d’ontologie dans chaque champ
- Utilisé par MetaboLights

- **SDRF (Sample and Data Relationship Format) :**

- Pour proteomics et métabolomique LC-MS / GC-MS.
- Lie échantillons → fichiers mzML / raw
- Définit des “templates” par type d’expérience (human, plant, lc-ms-metabolomics, etc)
- Utilisé par ProteomeXchange et PRIDE

linkedISA: semantic representation of ISA-Tab experimental metadata



<https://isa-tools.org/linkedISA/>



<https://www.ebi.ac.uk/pride/markdownpage/sdrf>



Formats de données en Spectrométrie de masse

Format clef	Rôle
mzML	Stocke les spectres et les métadonnées d'acquisition (données spectrales brutes)
mzMLb	Stocke ces données dans une structure HDF5 optimisée
mzTab-M	Rapporte les identifications et quantifications métabolomiques (petites molécules)
mzQC	Sert à communiquer les métriques de contrôle qualité des données MS
mzIdentML	Décrit les identifications protéomiques détaillées
mzQuantML	Permet une description plus complète de la quantification

- **Le message clé :** aujourd'hui, on tend vers des **profils d'interopérabilité** complets :
 - mzML / mzMLb (données brutes).
 - mzTab-M (résultats traités, avec vocabulaire contrôlé), mzQC pour les métriques
 - USI -*Universal Spectrum Identifier* pour dépôts GNPS, MassIVE, MetaboLights ou Metabolomics Workbench...
- **Modèles structurés:** ISA-Tab ou RDFS



Format de données en RMN

- **Différents formats selon technologies : IRM ou spectroscopie RMN**

Format clé	Rôle
DICOM	Standard international pour les images IRM (clinique et recherche).
ISMRM-Raw Data format	Standard pour les données brutes k-space en recherche IRM.
JCAMP-DX	Format d'échange de spectres RMN recommandé par l'IUPAC.
nmrML	Standard XML pour la RMN en chimie et métabolomique (COSMOS, MSI).
Formats propriétaires (Bruker, Varian/Agilent, JEOL, etc.)	Formats natifs des spectres RMN, utilisés en interne dans les laboratoires.

- **Message clef pour la spectro RMN (métabolomique, chimie) :**
 - fournir les spectres dans un format ouvert (JCAMP-DX, NMR-ML) ou au-moins les paramètres expérimentaux complets (fréquence, solvant, référence pour la représentation graphique et la notation, traitement du signal).
 - **Modèle structuré : ISA-Tab**



Formats de données en Chromatographie (LC/GC)

Format / standard clé	Rôle
MSI	Métadonnées minimales à rapporter pour LC/GC-MS (colonne, gradient, détecteur, échantillon).
mzML/mzXML (HUPO-PSI)	Standard d'échange pour spectres MS et chromatogrammes (LC-MS, GC-MS).
Allotrope (ADF + ontologies)	Modèles et ontologies pour instruments, méthodes et résultats chromatographiques.
Formats propriétaires (Thermo .raw, Agilent .D, Waters .raw, etc.)	Formats natifs des données chromatographiques, riches en métadonnées mais spécifiques aux constructeurs.

- **Message clef :**
 - Pas de réelle normalisation mais un « écosystème de standards » qui doivent être combinés avec des ontologies
 - Cadre structuré pour décrire investigations, études et essais incluant chromatographie : ISA-Tab



Workflow type “FAIR → IA”

- **La chaîne complète peut donc être représentée ainsi :**

Conception de l'étude



Métadonnées structurées (ISA-Tab ou SRDF)



Données LC-MS / GC-MS / RMN



Features quantitatives



Annotations ChEBI / RefMet + confiance MSI



Harmonisation par ontologies



Matrice features × échantillons correctement typée



Modèles d'IA



Features importantes / biomarqueurs candidats



Interprétation explicable et biologiquement contextualisée :

Métabolites → voies métaboliques → fonctions biologiques →
phénotypes cliniques

Métadonnées



Annotations



Sémantique



Modèles d'IA



Interprétation
biologique

Comment ça aide concrètement l'IA ?



FAIR & AI-READY DATA

Étape du workflow	Apport principal pour l'IA
Conception de l'étude : schéma ISA-Tab avec champs obligatoires (diagnostic, échantillon, protocole)	→ contexte et réduction des biais : pour l'IA, cela permet de distinguer une variation réellement biologique d'une variation potentiellement liée au protocole ou au type d'échantillon.
Génération des données : LC-MS/GC-MS/NMR, fichiers mzML, table de features	→ représentation numérique standardisée des observations : l'IA peut alors rechercher des signatures ou des combinaisons de features associées à un diagnostic ou à un phénotype.
Traitements/Annotations : métabolites avec ChEBI, RefMet, niveaux de confiance MSI	→ connaissance biologique et gestion de l'incertitude : cela évite qu'un modèle traite comme une vérité certaine une annotation qui n'est qu'une hypothèse.
Dépôt FAIR : EU MetaboLights, US Metabolomics Workbench ou entrepôt hospitalier FR avec métadonnées enrichies	→ reproductibilité, comparaison et généralisation : Pour l'IA, cela ouvre la possibilité de réutiliser plusieurs cohortes ; comparer différents protocoles ; entraîner des modèles sur plusieurs études ...

Comment ça aide concrètement l'IA ?



FAIR & AI-READY DATA

Étape du workflow	Apport principal pour l'IA
• Ontologies + Pipeline automatique : lecture des métadonnées, harmonisation des variables via les ontologies, construction de tables “features × échantillons” avec colonnes bien typées	On obtient alors des métadonnées avec concepts normalisés, des variables typées : matrice utilisable par l'IA. → compréhension sémantique et intégration de données hétérogènes
• Entraînement de modèles : classification, régression, réseaux de neurones, etc	Une fois les données correctement structurées, différents modèles peuvent être entraînés → l'IA apprend des relations entre métabolites et phénotypes
• Interprétation : features importantes reliées à des concepts cliniques et biologiques (voies métaboliques, phénotypes...) .	On peut comprendre ce qui a été analysé, comment, ce que représente chaque variable et quelle signification biologique lui attribuer et expliquer les prédictions en termes biologiques compréhensibles .



Types de tâches IA bénéficiant de données FAIR + ontologies...rêvons

- **Intégration multi-cohortes / multi-espèces :**

- Combinaison de plusieurs études grâce à une sémantique commune.
- Méta-analyses, transfer learning entre espèces (plantes, levures ↔ humain pour certaines voies).
- Découverte de biomarqueurs (signatures métabolomiques robustes entre cohortes)

- **Intégration multi-omiques (métabolomique + génomique + transcriptomique + clinique) :**

- Prédiction de phénotypes à partir de profils métabolomiques + données cliniques.

- **Recommandations / aide à la conception d'expériences / prédictions :**

- Systèmes qui suggèrent des conditions, des matrices, des métabolites cibles en fonction de la littérature structurée.
- Pronostic et suivi (évolution, réponse au traitement, risque de complications)
- Prédiction de maladies (classification sain vs malade)



Risques si on ignore les ontologies

- **Variables mal définies → mauvais alignement entre datasets :**
 - Exemple : “Glucose” ≠ “glucose sanguin à jeun” ≠ “glucose intracellulaire”
- **Impossibilité de réutiliser les données pour d’autres questions sans gros travail manuel.**
- **Modèles biaisés ou non généralisables, difficulté à auditer et expliquer les modèles.**
 - Diagnostics mal définis (mélange de types de diabète, de cancers, etc.)
 - Échantillons mal distingués (plasma vs sérum vs sang total)
 - Incertitude sur les populations, conditions, traitements inclus
 - Perte de confiance des cliniciens et des régulateurs dans les outils IA



Exemple d'utilisation - Cas 1 : Etudes de maladies chroniques

- **Scénario typique : plusieurs cohortes sur risque cardiovasculaire, diabète, cancer...**
 - Exemple : deux études, l'une en France, l'autre au Canada.
- **Sans ontologies : diagnostics et types d'échantillons décrits de façon hétérogène**
 - Métabolites avec noms libres : "glucose", "Glc", "D-glucose", "Cholestérol total", "TC", "total cholesterol"
 - "HTA", "hypertension artérielle", "high blood pressure"
- **Avec ontologies :**
 - Diagnostic → NCIT:C2985 ou DOID:9351 (diabète de type 2)
 - Échantillon → UBERON:0000178 (blood) + UBERON pour plasma/serum
 - Métabolite → ChEBI:17234 (glucose), ChEBI:16113 (cholestérol total)
 - Hypertension → NCIT:C3133 / DOID:1067 / CIM-10 I10
- **Résultat :**
 - Fichier sémantiquement clair, combinable avec d'autres études
 - Pipeline IA capable de fusionner les tables et d'entraîner des modèles sur l'ensemble des cohortes




Exemple d'utilisation - Cas 2 : Études sur l'exposome

- **Contexte : Travailleurs exposés à des mélanges chimiques (solvants, métaux lourds, pesticides, fumées).**
 - Données :
 - Expositions professionnelles (postes, tâches, durées, EPI).
 - Mesures d'ambiance (air, surfaces).
 - Biomarqueurs urinaires / sanguins.
 - Santé : maladies respiratoires, cancers, troubles métaboliques.
- **Apport des ontologies :**
 - Codage des postes et expositions (vocabulaires professionnels + ENVO).
 - Identification des composés (ChEBI, DSSTox).
 - Liens avec maladies (NCIT, DOID) et phénotypes (HPO).
- **Bénéfice pour l'IA :**
 - Modèles de prédiction de risque basés sur des profils d'exposition + métabolomique.
 - Possibilité de transférer des modèles entre secteurs professionnels similaires.



Exemple d'utilisation - Cas 3 : Etudes sur alimentation, additifs et santé

- **Contexte : Étude de l'impact des additifs alimentaires, contaminants et résidus de pesticides sur le métabolome.**
- **Données :**
 - Consommations alimentaires (questionnaires, journaux).
 - Composition des aliments (additifs, ingrédients, procédés)
 - Métabolomique urinaire / plasmatique
- **Apport des ontologies :**
 - Aliments et ingrédients /procédés de transformation : FoodOn, TransformON
 - Additifs et contaminants : classifications chimiques (ChEBI, DSSTox, réglementations).
 - Liaison avec métabolites endogènes et xénobiotiques (ChEBI, RefMet, FOBI...).
- **Bénéfice pour l'IA :**
 - Modèles liant patterns alimentaires → exposome chimique → métabolome → santé (obésité, diabète, maladies inflammatoires).



3^{ème} partie : Que faire demain dans vos projets ?

Mise en œuvre pratique

Exemple d'application : les études d'exposome en santé



- **Définition classique de l'exposome :**

“L'ensemble des expositions environnementales (chimiques, physiques, biologiques, sociales) tout au long de la vie et leur relation avec la santé.”

- **En métabolomique :**

- On mesure à la fois des métabolites endogènes et des métabolites d'exposition (xénobiotiques)
- Objectif: Intégrer les métabolites environnementaux en métabolomique humaine pour étudier le lien **exposome** → **métabolome** → **effets biologiques**

Environnement (air, eau, alimentation, stress...)

Exposition



Métabolites (endogènes + xénobiotiques)

Défis liés à l'exposome et aux études en santé



- **Diversité chimique énorme :**

- Pesticides, plastifiants, solvants, additifs alimentaires, médicaments, etc.
- Nombreux métabolites inconnus ou partiellement identifiés.

- **Multiplicité des sources et voies d'exposition :**

- Alimentation, air intérieur/extérieur, eau, poussière, produits cosmétiques, milieu professionnel.

- **Dimension temporelle :**

- Expositions aiguës vs chroniques, fenêtres critiques (grossesse, petite enfance).

- **Hétérogénéité des données :**

- Questionnaires, capteurs, mesures environnementales, biomarqueurs urinaires/sanguins, métabolomique globale.

- **Plus largement :**

- Lien Alimentation & Santé
- One Health (Santé globale)

➤ nécessité de traiter encore plus de données multidisciplinaires




Enjeux des données FAIR pour les études en santé



- **Findable** : Pouvoir retrouver des études par type d'exposition (pesticides, phtalates, PFAS, etc.), par matrice (urine, sang, air, poussière), par population, par type de diète (habitudes alimentaires)....
- **Accessible** : Gérer les aspects éthiques et juridiques (données de santé, données d'exposition parfois sensibles).
- **Interoperable** : Pouvoir manipuler les concepts sans ambiguïté : sources d'exposition (alimentation, air, travail), composés chimiques (pesticides, additifs, polluants), biomarqueurs internes (métabolites urinaires / sanguins), effets sur la santé (maladies, phénotypes).
- **Reusable** : Permettre la réutilisation pour d'autres questions (ex. passer d'un focus "cancer" à "maladies métaboliques").

De FAIR à « AI-ready » pour les études en santé



• L'IA a besoin de :

- Variables d'exposition bien définies (quoi, quand, comment la mesure a été réalisée).
- Composés chimiques clairement identifiés (identifiants stables, structures).
- **Liens explicites** entre source d'exposition → composé → biomarqueur interne → effet santé.


• Sans ontologies :

“Pesticides”, “produits phytosanitaires”, “insecticides” utilisés de façon incohérente.

“Bisphénol A”, “BPA”, “bisphenol A” sans lien explicite.

→ **Difficulté à combiner des études avec des questionnaires et des mesures différentes.**

- **Les ontologies permettent de structurer sémantiquement l'exposome et d'identifier les concepts de façon unique → indispensables pour des modèles IA robustes.**



Checklist “FAIR + ontologies” pour un projet d’étude clinique en métabolomique



- **Définir un jeu minimal de métadonnées obligatoires :**

- Sujet : âge, sexe, phénotypes clés, types d'exposition, alimentation, ...
- Échantillon : matrice, conditions de prélèvement et de conservation
- Instrument : type, paramètres clés
- Méthode (ciblé vs non ciblé)
- Métabolites : identifiants chimiques, niveaux de confiance

Métadonnées

- **Choisir un schéma de métadonnées adapté :**

- ISA-Tab / ISA-JSON, SDRF, ou template interne inspiré de ces standards

Schéma
(modèle)

- **Identifier les ontologies ou vocabulaires pertinents :**

- Composés, métabolites : ChEBI, RefMet, PubChem, DSSTox....
- Échantillons / matrices : UBERON, PO, FoodON, TransformON ...
- Protocoles / investigations : OBI, MS...
- Environnement : ENVO, AGROVOC...
- Diagnostics: MONDO, NCIT, DOID, CIM, SNOMED...

Vocabulaire
contrôlé

Conclusion et discussion !

Conclusion : Messages clés à retenir



- Les principes FAIR sont un socle pour des données réutilisables par des humains et des machines.
- Les ontologies et vocabulaires contrôlés sont essentiels pour l'interopérabilité sémantique, donc pour l'AI-readiness.
- Des standards existent et sont utilisables !
- Une approche progressive et communautaire est réaliste :
 - Commencer petit, mais structuré, puis enrichir.
 - Objectif final : des données qui permettent non seulement de publier, mais de construire des modèles IA robustes, interprétables et réutilisables.




Une stratégie progressive




- **Ne pas viser la perfection immédiate :**
 - Commencer par un noyau minimal de métadonnées bien annotées.
 - Étendre progressivement (plus de champs, plus d'ontologies).
- **Impliquer :**
 - Les data stewards / gestionnaires de données.
 - Les bioinformaticiens / biostatisticiens pour l'aspect "AI-ready".
 - Les cliniciens pour adéquation avec la pratique et le vocabulaire médical
 - Les communautés (consortiums métabolomique, plantes, aliments) pour adopter des standards communs.
- **Viser à terme :**
 - Knowledge graphs / FAIR Digital Objects pour l'intégration de données multi-cohortes et multi-omiques
 - Agents IA pour la modélisation, l'aide à l'interprétation.
 - Digital Twins

Sans standard



Avec standard




<https://kitoutils.com/outils/le-standard>

Discussion – échanges autour de vos pratiques




- Quels sont vos goulots d'étranglement actuels pour partager / réutiliser des données métabolomiques ?
- Utilisez-vous déjà des ontologies ?
Lesquelles ? Dans quels formats ?
- Quels freins voyez-vous à l'adoption de schémas de métadonnées plus stricts ?
- Avez-vous des projets où l'IA est limitée par la qualité des métadonnées ?



<https://www.redpill-linpro.com/techblog/2026/02/27/Ontology-Guide.html>

Merci pour votre attention et les échanges



Contact: magalie.weber@inrae.fr